

회전설비 고장 유형 조기 판별

AI4I 2020 Predictive Maintenance Dataset 기반 워업 프로젝트 결과보고서

분석 범위 전체 로드맵을 모두 수행하지 않고, 정상/고장 이진 판별을 중심으로 전처리-시계열성 검토-기준모델-머신러닝-오류 분석의 기본 흐름을 빠르게 경험하는 것을 목표로 하였다. 고장 유형은 별도 다중분류 모델이 아니라 오류 분포 해석에 활용하였다.

1. 문제 정의

산업용 회전설비는 토크, 회전속도, 온도, 공구 마모 등 운전 조건이 복합적으로 변하며 고장 상태에 접근한다. 본 분석은 AI4I 2020 데이터의 운전 변수를 이용해 현재 관측값이 정상인지 고장인지 판별하고, 모델이 놓치는 고장이 어떤 유형에 집중되는지 확인하는 것을 목적으로 한다.

항목	정의
대상	회전설비의 가상 제조 운전 데이터(AI4I 2020)
정상/이상	Machine failure = 0 / 1
주요 목표	기준모델과 ML 모델의 고장 탐지 성능 비교
성공 기준	Precision, Recall, F1, 혼동행렬로 평가하고 미탐 사례를 구체적으로 해석

데이터는 정상 표본이 압도적으로 많기 때문에 Accuracy 만으로 성능을 판단하지 않고, 고장 클래스의 Recall 과 F1-score 를 핵심 지표로 사용하였다.

2. 데이터 개요

데이터 출처는 UCI Machine Learning Repository 의 AI4I 2020 Predictive Maintenance Dataset 이다. 원본은 10,000 행, 14 개 컬럼이며 결측치와 완전 중복 행은 확인되지 않았다.

구분	내용
주요 입력	Air/Process Temperature, Rotational Speed, Torque, Tool Wear, Product Type
Target	Machine failure (0: Normal, 1: Failure)
원본 분포	정상 9,661 건 / 고장 339 건 (고장 3.39%)
시간 정보	실제 timestamp 또는 측정 기간 정보 없음

고장 유형 라벨은 HDF 115 건, OSF 98 건, PWF 95 건, TWF 46 건, RNF 19 건이었다. 동시에 2 개 유형이 표시된 행이 23 건, 3 개 유형이 표시된 행이 1 건 존재하였다. 또한 Machine failure=1 인데 세부 유형이 없는 행이 9 건 확인되었다.

RNF 는 19 건 중 18 건이 Machine failure=0 으로 표시되어 이진 Target 과의 불일치가 확인되었다. 따라서 유형별 오류 분석에서는 RNF 를 제외했으며, 이진분류 Target 자체는 원본 Machine failure 라벨을 그대로 사용하였다.

3. 전처리

3.1 처리 절차

- Product ID 는 식별자이므로 모델 입력에서 제거하였다. UDI 는 모델 학습에는 사용하지 않고 진행 순서 측과 오류 사례 위치 확인에만 활용하였다.
- Product Type(L/M/H)은 One-Hot Encoding 을 적용했으며 drop_first=True 로 Type_L, Type_M 두 변수를 생성하였다.
- 결측치는 원본에 없었으며, rolling 연산으로 생긴 초기 NaN 만 제거하였다. window=10 으로 인해 최종 데이터는 10,000 행에서 9,991 행으로 감소하였다.

3.2 물리 기반 파생변수

파생변수	정의	의도
Temp_Diff	Process Temperature - Air Temperature	공정-주변 온도 차이 표현
Mechanical_Power	Torque x (2π x RPM / 60)	회전축의 기계적 동력 수준 표현
Wear_Torque	Tool Wear x Torque	누적 마모와 현재 부하를 결합한 지표

3.3 진행 순서 기반 특성

실제 timestamp 가 없기 때문에 엄밀한 시간 시계열로 간주하지 않고, 데이터의 행 순서를 진행 순서로 두어 최소 수준의 rolling/difference 특성을 생성하였다.

특성	계산	해석
Torque_MA	최근 10 개 Torque 의 평균	단기 평균 부하 수준
Torque_STD	최근 10 개 Torque 의 표준편차	단기 부하 변동성
RPM_Diff	현재 RPM - 직전 RPM	회전속도의 급격한 변화

3.4 학습/평가 분할과 불균형 대응

과제의 순서 기반 분할 원칙에 맞춰 무작위 셔플 없이 앞 80%를 Train, 뒤 20%를 Test 로 분할하였다. 최종 Train 은 7,992 건, Test 는 1,999 건이다.

구간	정상	고장	고장 비율
Train	7,692	300	3.75%
Test	1,960	39	1.95%

불균형 데이터에 대응하기 위해 Logistic Regression 과 Random Forest 모두 class_weight="balanced"를 적용하였다. Test 분포는 실제 평가를 위해 원래 비율을 유지하였다.

주의 Train 과 Test 의 고장 비율이 서로 다르며 Test 에는 고장이 39 건뿐이다. 따라서 높은 Accuracy 가 곧 높은 고장 탐지 성능을 의미하지 않는다.

4. 시계열 분석

실제 시간 정보가 없으므로 UDI를 실제 시간으로 해석하지 않고 데이터의 진행 순서를 나타내는 축으로 사용하였다. 그림의 x 표시는 Machine failure=1 인 지점이다. 아래 결과는 고장 직전의 인과적 시간 패턴을 증명하기보다, 진행 순서상 변수의 변동과 고장 지점의 중첩을 탐색하는 목적이다.




그림 1. Torque와 10-point 이동평균 및 고장 지점

Torque 원신호는 대체로 40 Nm 전후에서 넓게 변동하며, 고장 지점은 낮은 토크와 높은 토크 양쪽에 모두 분포한다. 이동평균은 급격한 순간 변동을 완화하지만, 고장 지점만을 독립적으로 분리할 정도의 뚜렷한 수준 변화는 관찰되지 않았다.




그림 2. Torque Rolling STD와 고장 지점

Rolling STD는 대체로 약 5~15 범위에서 변동한다. 일부 고장 지점에서 변동성이 높게 나타나지만 정상 구간과도 광범위하게 겹치므로, 변동성 하나만으로 고장을 구분하기는 어렵다.

4. 시계열 분석 - 변화율 특성




그림 3. RPM 차분값과 고장 지점

RPM_Diff 는 0 을 중심으로 큰 양·음의 변화가 반복되며, 고장 지점에서도 큰 변화가 나타나는 사례가 있다. 그러나 정상 지점에서도 유사하거나 더 큰 변화가 다수 존재한다. 따라서 단일 변화율 기준보다는 여러 운전 변수와 파생특성을 함께 사용하는 분류모델이 필요하다고 판단하였다.

4.1 시계열 분석 결과 요약

관찰 항목	결과	모델링 시사점
Torque 평균 수준	고장/정상 구간이 상당 부분 중첩	단일 임계값만으로 분리 어려움
Torque 변동성	일부 고장에 높은 STD 가 있으나 정상과 중첩	보조 특성으로 활용
RPM 변화량	큰 변화가 고장과 정상 모두에 존재	다변량 결합 필요

이 결과를 바탕으로 이후 모델에서는 원본 변수와 물리 파생변수, 진행 순서 기반 특성을 함께 사용하였다. 최종 입력 특성은 총 13 개이다.
Air temperature, Process temperature, Rotational speed, Torque, Tool wear, Type_L, Type_M, Temp_Diff, Mechanical_Power, Wear_Torque, Torque_MA, Torque_STD, RPM_Diff

해석 범위 본 분석은 실제 센서 timestamp 가 없는 데이터의 행 순서를 이용한 워업 분석이다. 따라서 주기성, 선행시간, 고장 직전 변화와 같은 정밀 시계열 결론은 제시하지 않는다.

5. 모델링

5.1 기준 모델: Z-score

Train 구간에서 11 개 연속형 특성의 평균과 표준편차를 계산하고, Test 에서 하나의 특성이라도 $|Z| > 3$ 이면 고장으로 판정하였다. 이 모델은 복잡한 머신러닝 전에 단순 통계 이상치 기준이 어느 정도의 탐지력을 가지는지 확인하기 위한 baseline 이다.



그림 4. Z-score 기준모델 혼동행렬

Precision	Recall	F1-score	TN	FP	FN	TP
0.196	0.231	0.212	1,923	37	30	9

고장 39 건 중 9 건만 탐지하여 Recall 이 0.231 에 그쳤으며, 정상 37 건을 고장으로 오탐하였다. 단순한 극단값 탐지 규칙만으로는 고장 상태를 충분히 표현하기 어렵다는 기준점이 되었다.

5.2 머신러닝 모델

비교 모델은 Logistic Regression 과 Random Forest 로 제한하였다. 두 모델 모두 `class_weight="balanced"`를 적용해 소수 클래스인 고장의 학습 가중치를 높였다. Logistic Regression 에는 StandardScaler 를 적용했고, Random Forest 는 200 개 트리를 사용하였다.

Model	Precision	Recall	F1-score
Z-score Baseline	0.196	0.231	0.212
Logistic Regression	0.205	0.641	0.311
Random Forest	1.000	0.615	0.762

Logistic Regression 은 Recall 이 가장 높았지만 정상 97 건을 오탐하여 Precision 이 0.205 에 머물렀다. Random Forest 는 Recall 이 0.615 로 약간 낮았으나 FP=0, F1=0.762 로 전체 균형이 가장 좋아 최종 모델로 선정하였다.

6. 평가와 오류 분석

6.1 최종 Random Forest 평가




그림 5. Random Forest 혼동행렬

Metric	Score	해석
Precision	1.000	고장으로 예측한 24 건이 모두 실제 고장
Recall	0.615	실제 고장 39 건 중 24 건 탐지, 15 건 미탐
F1-score	0.762	Precision 과 Recall 의 조화평균
Accuracy	0.992	전체 1,999 건 중 1,984 건 정분류

Accuracy는 99.2%로 매우 높지만, 이는 Test의 98.0%가 정상인 불균형 구조의 영향을 크게 받는다. 실제 고장 중 38.5%(15/39)를 놓쳤기 때문에 현장 보전 관점에서는 Accuracy보다 Recall과 FN을 함께 봐야 한다.

6.2 기준모델 대비 개선

Z-score 대비 Random Forest는 Precision 0.196→1.000, Recall 0.231→0.615, F1 0.212→0.762로 개선되었다. 즉 단일 변수의 극단값 여부보다 여러 운전조건 및 파생특성의 비선형 조합을 활용하는 방식이 이 데이터에서 더 효과적이었다.

핵심 결과 최종 모델은 오탐(FP)은 발생시키지 않았지만 미탐(FN) 15 건이 남았다. 따라서 이번 월업의 핵심 오류 분석 대상은 미탐 사례이다.

6. 평가와 오류 분석 - 미탐 사례

6.3 고장 유형별 탐지/미탐

Failure Type	Test 내 표기 건수	Detected (TP)	Missed (FN)	탐지율
TWF	10	1	9	10.0%
HDF	0	0	0	평가 불가
PWF	10	8	2	80.0%
OSF	21	18	3	85.7%

유형별 건수 합계가 Test 의 고장 39 건보다 클 수 있는 이유는 일부 행에 둘 이상의 고장 유형 라벨이 동시에 존재하기 때문이다. HDF 는 Test 구간 에 표본이 없어 해당 유형의 탐지 성능을 판단할 수 없다.

가장 두드러진 결과는 TWF 10 건 중 9 건을 놓친 점이다. 반면 PWF 와 OSF 는 각각 80.0%, 85.7%가 탐지되었다. 이는 현재 입력 특성과 Random Forest 가 전력/과부하 성격의 패턴은 비교적 잘 분리했지만, 일부 공구 마모 고장은 정상 영역과 겹쳐 구분하기 어려웠을 가능성을 시사 한다. 이 문장은 모델 결과에 기반한 해석이며 인과관계의 증명은 아니다.

6.4 대표 미탐 사례: UDI 8027




그림 6. UDI 8027 전후 Torque 변화와 미탐 지점

UDI 8027 은 실제 Machine failure=1, OSF=1 이지만 최종 모델은 정상으로 예측하였다. 해당 시점 Torque 는 50.2 Nm 이고, 주변 구간에서도 약 20~60 Nm 범위의 큰 변동이 반복된다. 그림만 보면 미탐 지점이 주변 대비 독립적인 극단값으로 두드러지지 않는다. 따라서 이 사례는 단순한 순간 토크 수준만으로는 고장 판별이 어렵다는 점을 보여준다.

최종 모델에서 FP=0 이므로 실제 오탐 사례는 존재하지 않았다. 과제의 오탐/미탐 분석 요구 중 오탐은 “발생하지 않음”으로 기록하고, 미탐 원인 분석을 중심으로 정리하였다.

7. 보전 관점 해석

본 모델은 현장 적용 시 “고장 유형을 확정하는 진단기”보다는 현재 운전조건에서 이상 위험이 높은 설비를 1 차 선별하는 스크리닝 도구로 해석하는 것이 적절하다. Random Forest 가 고장으로 판정한 Test 사례에서는 오탐이 없었기 때문에 경보 신뢰도는 높았지만, 실제 고장의 38.5%를 놓쳤다는 점에서 단독 안전장치로 사용하기에는 부족하다.

관점	현장 의미
Precision 1.000	모델이 고장 경보를 낸 경우 불필요한 점검 경보가 적었음
Recall 0.615	고장 10 건 중 약 4 건은 놓칠 수 있어 미탐 비용이 큰 설비에는 보완 필요
TWF 미탐 집중	공구 마모 상태를 설명하는 추가 센서/누적 이력 또는 전용 진단 로직 필요
FP=0	이번 Test 결과에 한정된 결과이며 다른 기간/설비에서도 유지된다고 단정할 수 없음

Random Forest 의 분류 임계값은 별도 최적화 없이 기본값 0.5 를 사용하였다. 실제 보전에서는 미탐 비용이 오탐 비용보다 크다면 임계값을 낮춰 Recall 을 높이는 방향을 검토할 수 있으나, 이번 원업에서는 임계값 조정 실험을 수행하지 않았다.

8. 한계와 개선 방향

한계	개선 방향
실제 timestamp 부재	설비별 실제 시간 이력과 고장 발생 시각을 확보해 선행시간 기반 평가
Test 고장 39 건, HDF 0 건	더 많은 고장 이벤트와 유형별 균형 표본 확보
RNF/유형 라벨 불일치 및 중복	라벨 정의와 이벤트 기준을 정리한 정제 데이터셋 구축
행 순서 기반 rolling	설비 개체 ID 와 실제 시간 경계를 고려한 그룹별 rolling 적용
미탐 15 건	Threshold 조정, 비용민감 학습, 추가 센서 및 마모 이력 특성 검토
유형별 다중분류 미수행	후속 프로젝트에서 TWF/HDF/PWF/OSF 분류 모델을 별도로 구축

결론

이번 원업 프로젝트에서는 10,000 건 규모의 AI4I 데이터를 이용해 전처리, 진행 순서 기반 특성 생성, Z-score 기준모델, 불균형을 고려한 머신러닝 비교, 혼동행렬 및 미탐 분석의 전체 흐름을 수행하였다. 최종 Random Forest 는 Precision 1.000, Recall 0.615, F1 0.762 를 기록해 Z-score 기준모델보다 뚜렷하게 개선되었다. 동시에 TWF 미탐과 Test 유형 불균형, 실제 시간 정보 부재라는 한계도 확인하였다. 따라서 본 결과는 완성된 예지보전 시스템이라기보다, 실제 설비 데이터를 이용한 후속 프로젝트에서 무엇을 추가로 수집·검증해야 하는지를 확인한 기초 분석으로 의미가 있다.

프로젝트 수행 후 느낀점

회전설비 고장 유형 조기 판별 · 팀원별 소감

프로젝트 소감 데이터 전처리, 시계열 특성 생성, 기준모델과 머신러닝 비교, 성능 평가 및 오류 분석 과정을 수행한 뒤 각 팀원이 느낀 점을 정리하였다.

팀원별 느낀점

송지호	이번 프로젝트를 통해 불균형 데이터에서는 정확도만으로 모델 성능을 판단하기 어렵고, Precision·Recall·F1-score를 함께 확인해야 한다는 점을 확인했습니다. 또한 전처리와 특성 생성 방식에 따라 모델 결과가 달라질 수 있어 데이터 이해가 중요하다는 점을 느꼈습니다.
원종준	이번 프로젝트를 통해 단순히 고장 여부를 예측하는 것뿐 아니라, 데이터의 불균형과 실제 시간 정보의 부재 등 분석 과정에서 고려해야 할 점을 배웠습니다. 또한 여러 운전 변수를 함께 분석하는 머신러닝이 단일 변수 기준보다 효과적일 수 있음을 확인했으며, 미탐 사례를 분석하는 것이 설비 고장 예방에 중요하다는 것을 느꼈습니다.
김예민	이번 프로젝트를 진행하면서 처음에는 모델의 정확도가 높으면 좋은 모델이라고 생각했지만, 고장 데이터가 적은 불균형 데이터에서는 Recall과 F1-score를 함께 봐야 한다는 점을 배웠습니다. 또한 Z-score 같은 단순한 기준보다 여러 변수를 함께 활용한 머신러닝 모델이 고장을 더 잘 판별한다는 것을 확인했습니다. 하지만 TWF와 같이 모델이 잘 잡지 못하는 고장도 있어, 어떤 고장을 놓쳤는지 분석하는 과정도 중요하다는 것을 알게 되었습니다. 이번 프로젝트를 통해 데이터 전처리부터 시각화, 모델링, 오류 분석까지 전체 흐름을 경험할 수 있었습니다.
한재민	이번 프로젝트를 통해 정상 데이터가 압도적으로 많은 불균형 데이터 구조 속에서는 단순한 정확도 수치에 현혹되지 않고 재현율(Recall)과 미탐 사례를 세밀하게 분석하는 것이 실제 현장 관점에서 얼마나 중요한지 깊이 깨달았습니다. 또한 토큰나 RPM 등의 변동 구간이 넓게 겹쳐 단일 임계값으로는 분리가 어려울 때, 물리 기반 파생변수와 머신러닝의 다변량 조합을 활용하는 방식이 고장 판별에 훨씬 효과적이라는 점을 배울 수 있었습니다.
한찬희	실제 센서의 타임스탬프 정보가 부재하고 특정 고장 유형의 표본이 부족한 한계 속에서도, 데이터의 진행 순서를 바탕으로 롤링 특성을 생성하며 전처리부터 기준모델, 머신러닝 비교, 오류 분석까지 이어지는 예지보전 분석의 전체적인 흐름을 빈틈없이 경험할 수 있었습니다. 특히 오탐은 발생하지 않았으나 공구마모 고장(TWF) 등에서 미탐이 집중된 원인을 파악하며, 향후 현장 적용 시 스크리닝 도구로서 모델의 신뢰도를 높이기 위해 어떤 추가 데이터와 보완 로직이 필요한지 시야를 넓힐 수 있었습니다.